

# Note d'Insights — E5 : Topic Modeling & NER

Analyse du corpus Ziwig | Mai 2026

## 1. Vue d'ensemble du corpus

Le corpus analysé contient **140 380 messages** issus de la plateforme Ziwig, principalement en langue française. Après modélisation, BERTopic a identifié **733 topics distincts**, dont les 10 premiers concentrent l'essentiel des discussions.

### Top 10 Topics identifiés par BERTopic :

| Topic      | Nb messages | Thème identifié                              |
|------------|-------------|----------------------------------------------|
| 0          | 4 732       | Douleurs chroniques & traitements de fond    |
| 1          | 1 546       | Coelioscopie & kystes ovariens               |
| 2          | 1 320       | Effets secondaires des traitements hormonaux |
| 3          | 1 288       | Menopause artificielle & injections          |
| 4          | 1 268       | Diagnostic IRM & coelioscopie                |
| 5          | 1 167       | Endometriose — parcours patient              |
| 6          | 1 035       | Urgences gynécologiques                      |
| 7          | 817         | Localisation géographique & suivi médical    |
| 8          | 805         | Enantone & traitements longue durée          |
| 9          | 721         | Grossesse & endometriose                     |
| -1 (bruit) | 84 733      | Messages non classes (hors sujet)            |

## 2. Extraction d'entites nominees (NER — spaCy)

Le modele **fr\_core\_news\_sm** a extrait **275 697 entites** du corpus. La repartition par type est la suivante :

| Type d'entite      | Nombre | Description                              |
|--------------------|--------|------------------------------------------|
| LOC (Localisation) | 90 480 | Lieux, villes, regions mentionnes        |
| MISC (Divers)      | 88 424 | Termes medicaux, medications, procedures |
| PER (Personne)     | 51 097 | Prenoms, pseudonymes d'utilisateurs      |
| ORG (Organisation) | 45 696 | Hopitaux, cliniques, structures de sante |

Les localisations les plus frequentes incluent des references a des villes françaises (Bordeaux, Aix-en-Provence) et des structures hospitalieres, confirmant un profil d'utilisateurs majoritairement en France.

## 3. Detection des irritants SAV

**10 434 messages** ont ete identifies comme contenant des signaux d'irritants SAV (Service Apres-Vente) sur un total de 140 380 messages, soit **7,4% du corpus**.

### Repartition par mot-cle detecte :

| Mot-cle | Occurrences | Signal |
|---------|-------------|--------|
|---------|-------------|--------|

|               |       |                                    |
|---------------|-------|------------------------------------|
| retour        | 4 642 | Retours produits / insatisfaction  |
| probleme      | 4 343 | Problemes generaux signales        |
| retard        | 1 483 | Delais de livraison / rdv          |
| erreur        | 314   | Erreurs de commande / prescription |
| casse         | 114   | Produits endommages                |
| remboursement | 70    | Demandes de remboursement          |
| default       | 65    | Defauts produit                    |
| reclamation   | 6     | Reclamations formelles             |
| livraison     | 14    | Problemes de livraison             |

## 4. Recommandations & prochaines etapes

- Axe 1 — Symptomes & traitements : Approfondir les topics 0, 2, 3, 8 qui regroupent les discussions sur la douleur, les effets secondaires et les traitements hormonaux.
- Axe 2 — Parcours diagnostic : Les topics 1, 4, 5 revelent un fort besoin d'information autour du diagnostic (IRM, coelioscopie), a exploiter pour du contenu educatif.
- SAV prioritaire : Les signaux 'retour' et 'probleme' representent plus de 85% des irritants SAV. Une analyse semantique approfondie est recommandee sur ces deux categories.
- Enrichissement NER : Filtrer les entites LOC pour cartographier la couverture geographique des utilisateurs et identifier les deserts medicaux mentionnes.
- Clustering final : Regrouper les 733 topics en axes strategiques (Axe1: Medical, Axe2: SAV/Experience) pour alimenter le rapport final E7.

Cette analyse constitue la base de la phase E6 (clustering avance) et E7 (rapport final). Les fichiers topics\_output.csv, entities.csv et sav\_irritants.csv sont disponibles dans le dossier outputs/.